DIGITAL LIFE · MEMORY ENGINE

工程报告

R0 候选评估与 NO-GO 结论

版本 1.0 · 2026-11-11 · AstrBot 4.29.3 / Windows 11

发布结论：R0 / R1 NO-GO

工程切片可审计；真实语料、真实宿主 72h、断电级 fsync 尚未完成。

1. 执行摘要

本报告汇总 Memory Engine 从基线、一致性、数据质量、检索、上下文、规模可靠性到真实宿主接入的工程证据。所有数字均来自本工作区的测试、评测脚本与运行记录；合成数据与真实用户数据严格区分。

- 离线回归：531/531；Windows CI 在 Python 3.10 / 3.11 / 3.12 全绿。
- R0 候选包：31 文件、52,580 bytes、SHA-256 09d108a0…，整包与逐文件哈希均校验。
- 21 例真实模型重判：六次 19–20/21；污染 0；T02-S2 稳定错误。
- 340 合成 trace：词面 F1 约 0.66；BGE top20 F1 0.8740/0.8782；BGE top30 回落到 0.8533。
- 100k：读 p95 458.8ms；备份 100k；kill 续跑 100k；4×25k 多 scope 续跑 0 重复。
- 真实宿主：AstrBot 4.29.3 testbed 10 次 shadow，52 events / 13 scopes，0 失败。
- 结论：R0/R1 NO-GO；不得接入 V1 生产或 Shadow。

维度	结论	证据强度
功能闭环	ingest/retrieve/context/delete/更正/撤回/历史可用	强（单测+CLI）
数据质量	合成数据可用；真实 gold 缺失	弱（合成）
检索质量	BGE 显著优于词面；延迟约 15×	中（合成 340）
规模可靠性	100k 读写/备份/恢复/续跑通过	中（简化图）
宿主接入	testbed shadow 10 次；无 72h	中弱（mock）
发布	R0/R1 NO-GO	—

2. 范围与边界

2.1 目标

验证并推进一个独立于 V1 的 Memory Engine：把私聊原文写成可追溯事件，按需检索并以未确认线索回注模型；所有决策 append-only、可回退、可审计。

2.2 明确不做

- 不修改 V1 生产插件、不改变 V1 的回复与注入路径。
- V1.5-B 作为独立 Sidecar 运行，不写 V1 数据库。
- 在 R0/R1 通过前，不把 Memory Engine 接入生产 Shadow。
- 不把合成 B4 或模型标注当作真实用户准确率。

2.3 证据等级

等级	含义	本项目例子
A	真实用户/真实宿主/可重复	无（尚未取得）
B	真实模型+合成输入	21 例、340 BGE
C	替身/模拟宿主	M7 testbed shadow
D	纯单测/静态	B4 契约、缓存、存储

本报告的结论按最低证据等级表述；D 级通过不等于 B/A 级通过。

3. 系统架构

事件流水线：B1 候选检索 → B2 LLM 关系判断 → B3 约束 Resolver → B4 append-only decisions/evidence。模型只给提案；是否附着由 Resolver 与 ProvenanceGuard 决定。

层	职责	关键实现
B1	候选事件召回	LexicalCandidateIndex / HybridCandidateIndex（BGE，RRF）
B2	关系提案	OpenAIProvider；超时/瞬时重试；严格 JSON
B3	约束解析	ConstrainedResolver；cannot-link、同故事归一化
B4	决策与证据	decisions/evidence/receipts；scope lease/fencing
M3	引擎 API	ingest/retrieve/context/delete/ revise/withdraw/history
M5	上下文	ContextPacket、摘要、tiktoken、持久缓存、HostBudget
M6	规模/生命周期	备份、恢复、续跑、自动备份锁
M7	宿主接入	AstrBot shadow 插件、宿主预算、preflight

可靠性基线：unit_of_work 全有或全无；scope lease + fencing token；source receipt；manifest；连续 frontier；source_ready 队列；PendingRejudger 处理暂定/重评。

4. 阶段完成情况

阶段	状态	主要证据	缺口
M0 基线	✅	531 测试、CI、manifest、R0 包	—
M1 一致性	◐	kill/续跑、pending 重评、provider 重试	真实模型 340 稳定性
M2 数据	◐	21 例六次、340 多组、污染 0	独立真实 gold
M3 引擎	✅	API/CLI、更正/撤回/历史	生产宿主采集
M4 检索	◐	词面/BGE、阈值、延迟	真实查询集
M5 上下文	✅	Packet/摘要/tiktoken/缓存/预算	宿主真实总预算
M6 规模	◐	100k 读/写/备份/恢复/续跑	断电 fsync
M7 接入	◐	testbed shadow 10 次、回退	真实 QQ 72h

5. 测试与 CI

统一命令：python -m unittest discover -q -s tests -t .；报告脚本：python scripts/report.py。

项	结果
离线用例	531
失败/错误	0 / 0
Windows CI	3.10 / 3.11 / 3.12 全绿
耗时	约 43 s（本机）
R0 包验证	哈希/字节/文件数/解压 ingest/retrieve 全过

- 测试覆盖存储、租约/fencing、Resolver、ProvenanceGuard、rejudge、worker、缓存、备份、渲染、token 预算、CLI。
- CI 曾出现 Windows integration flake；通过 warm-up + 20ms settle + 确定性 pending backlog 修复，未削弱断言。
- R0 包进入回归套件；曾发现遗漏 projection/summary/token 模块，解压导入失败，补齐后新增逐文件哈希校验。

6. 数据质量

6.1 21 例真实模型重判

run	event correct	story	污染	guard false reject
1	20/21	17/17	0	0
2	19/21	17/17	0	0
3	20/21	17/17	0	0
4	20/21	17/17	0	0
5	20/21	17/17	0	0
6	20/21	17/17	0	0

六次分布 19–20/21，均值 19.8；T02-S2 六次都错（同故事不同事件被判 DIFFERENT），其余稳定。Resolver 已把同 story 的 DIFFERENT 归一化为 RELATED_CONTEXT，但原始模型分数仍按 20/21 记录，不抬高指标。

6.2 340 合成 trace：词面 vs BGE

配置	attached	clusters	mixed	TP	FP	FN	F1
词面 k5	117	203	0	220	0	260	0.6286
词面 k10 run1	123	197	0	234	0	246	0.6555
词面 k10 run2	124	196	0	237	0	243	0.6611
BGE k10 run1	182	138	1	358	12	122	0.8424
BGE k10 run2	187	133	1	366	8	114	0.8571
BGE k20 run1	194	126	1	385	16	95	0.8740
BGE k20 run2	196	125	1	382	8	98	0.8782
BGE k30	192	128	2	378	28	102	0.8533

BGE 把召回从约 0.49 提到 0.80，F1 从 0.66 提到 0.876；top30 因 FP/mixed 增加回落，说明 20 附近接近饱和。所有数字仍是合成 B4，不是真实用户准确率。

6.3 FN 归因

原因	对数
B1 单边未召回	124
B3/暂定事件碎片化	136
合计	260

340 的瓶颈约一半在 B1 候选召回，另一半在 B3/暂定分片；继续调分类阈值不会消掉这些 FN。

7. 检索与延迟

项	结果
词面 R@1 / R@5 / MRR	0.7812 / 1.0 / 0.8891
BGE R@1 / R@5 / MRR	0.7937 / 1.0 / 0.8938
阈值 1.139（dev/holdout）	dev 69/69；holdout 91/91；注入 0
1000 anchors 词面 p95	2.80 ms
1000 anchors BGE p95	41.45 ms（约 14.8×）
BGE build	6,424 ms / 1000 anchors

Engine 支持 MemoryEngine(store, encoder=...)；CLI 支持 --bge-model。真实 CLI 探针能命中，但每次进程都重新加载 BGE，不适合逐命令生产调用。

BGE 是明确的“质量换延迟”：生产需要常驻索引、持久化向量或分层检索，而不是无条件全量。

8. 上下文、缓存与预算

- ContextPacket 稳定包含 scope、query、items、budget、degraded；渲染器输出最终模型 block。
- 摘要为抽取式，保留否定与不确定；tiktoken 预算为精确计数，缺库时保守估算。
- PersistentContextCache 支持跨实例、四进程共享、epoch 失效、prune、TTL 与 CacheJanitor（状态+锁+stale 清理）。
- HostBudget：memory_tokens = max(0, total - system - history - output)。
- testbed 真实请求：host_memory_tokens 5,684；rendered 197；items 2；V1 注入不变。

9. 规模与可靠性

场景	结果
100k 查询 p95	458.756 ms
100k 并发读 p95	0.766 ms
100k 单写	598.3 s
100k 多写	631.2 s
100k 备份	100,000 events；integrity ok
100k kill 续跑	693 → 100,000；0 重复
4×25k 多 scope 续跑	100,000 receipts/evidence；0 重复
100k 恢复查询	10 hits；151.87 ms；context 10
100k 恢复后继续写	新增 source 可检索；receipt 1；integrity ok
并发写入时备份	20 个快照；计数 0→2,579 单调；0 错误

写锁缺陷：多进程 BEGIN IMMEDIATE/release_scope 出现 database is locked；通过 busy_timeout=5000 + 退避重试修复，100k 多 scope 续跑通过。时间均为本机测量，不是生产 SLA。

10. 宿主接入

真实宿主：AstrBot 4.29.3 testbed，mock provider。M7 shadow 插件只观察、不修改请求/回复。

项	结果
成功运行	10 次
失败	0
shadow events / sources	52 / 52
scopes / observations	13 / 39
每次 V1 memory prefix	true
宿主预算	5,684 memory tokens；197 rendered
preflight	8 项全 true
回退	移除 shadow 后 V1 正常加载

部署陷阱：未设置 DIGITAL_LIFE_DEV 时，V1 仍正常，但 shadow 导入失败、DB 不增长，进程仍 exit 0。新增 preflight，未通过则 exit 1。

真实 QQ：V1 侧状态记录 NapCat 小号私聊 2 条；这不等于 Memory Engine M7 的 72h 证据。M7 的 10 次运行仍是 testbed；没有真实平台 72h 连续观察。

11. 缺陷与修复

编号/问题	修复	验证
P01 自动迁移绕过 Guard	relocate_pending 重跑 ProvenanceGuard	回归测试
P02 UNCERTAIN 被标 resolved	以 Resolver 结果为准	回归测试
P03 pending 绕过检索	SQL NOT EXISTS PENDING	回归测试
P04 缓存跨连接陈旧	data_version + scope_epoch	双连接测试
P05 重复 revision	revision_receipt 幂等	重复更正测试
P06 旧 generation 消费新任务	expected_generation CAS	worker 测试
B01 cannot-link 绕过	cannot_link_exists 检查	回归测试
B02 陈旧 generation 提交证据	事务内预检查	回归测试
B03 同连接缓存失效	scope_epoch	回归测试
B04 哈希冲突	revision identity 校验	回归测试
M6 多进程 database is locked	busy_timeout + BEGIN/release 重试	100k 续跑
R0 包缺模块	补齐 projection/summary/token，新增包测试	解压导入
shadow 环境变量缺失静默	preflight 8 项检查	testbed 实测
provider 瞬时网络错误	retries/backoff；HTTPError 不重试	单测

12. 验收与结论

层级	结论	原因
R0 独立离线引擎	NO-GO	真实 gold、宿主总预算、断电未完成
R1 目标宿主	NO-GO	无真实 QQ/NapCat 72h
Shadow/生产	禁止	缺验收证据

当前工程切片完整、可审计、可交接；但“能跑通”不等于“可发布”。R0 包是候选包，不是生产发布包。

13. 建议

- 先取得真实脱敏语料与独立人工 gold，重做 21/340，不以合成分数代替。
- 在真实 QQ/NapCat 上做 72h shadow，保留采样、错误与回退记录。
- 补断电/fsync 故障注入；至少明确接受“仅进程级故障”的降级边界。

- 用真实查询集校准 M4 阈值；BGE 先做常驻索引/持久向量，避免逐命令冷加载。
- 在 R0/R1 通过前，不接 V1 生产，也不把 shadow 结果当作用户效果。

14. 附录

14.1 产物

产物	值
R0 包	releases/memory-engine-r0-rc1.zip
大小/文件数	52,580 bytes / 31
SHA-256	09d108a09e8add187655ae17248b086c82e1492f2ad35cde7596d05d7b702884
代码提交	5dc2d24
测试	531/531

14.2 证据索引

文档	内容
MEMORY_ENGINE_ACCEPTANCE_2026-11-10.md	验收矩阵
M2_DATA_PROGRESS_2026-11-10.md	21/340/top-k/BGE/FN
M4_RETRIEVAL_QUALITY_2026-11-10.md	检索质量/延迟/CLI
M5_HOST_BUDGET_2026-11-11.md	宿主预算
M6_SCALE_SMOKE_2026-11-10.md	100k/备份/恢复/续跑
M7_SHADOW_SOAK_2026-11-11.md	shadow 10 次/preflight
R0_RC_BUNDLE_2026-11-11.md	R0 包/hash
FINAL_HANDOFF_2026-11-11.md	移交说明

14.3 复现命令

python -m unittest discover -q -s tests -t .

python scripts/report.py

python scripts/verify_r0_bundle.py

本报告由工作区报告、测试输出与运行记录汇总；未使用工作区外的真实用户数据。